

KgColPali: EFFICIENT DOCUMENT RETRIEVAL WITH VISION LANGUAGE MODELS AND KNOWLEDGE GRAPHS

Marcos LAHOZ

CentraleSupélec
Université Paris-Saclay

Stage M1 Mathématiques et IA
Année universitaire 2024-2025



CentraleSupélec



- **MICS:** (Mathématiques et Informatique pour la Complexité et les Systèmes), rattaché à CentraleSupélec, est un centre de recherche dédié à l'étude des systèmes complexes.
- **Encadrante:** Céline Hudelot, Directrice du Laboratoire MICS.
- **Sujet du stage:**
 - ▶ Stage de recherche de 4 mois sur les modèles **RAG** (Retrieval Augmented Generation).
 - ▶ Application des **Knowledge Graphs** pour améliorer les performances des RAG.
 - ▶ Objectif: découvrir un environnement de recherche en partant d'un travail existant (*Colpali*).

Les défis des LLMs

Pourquoi le RAG est-il nécessaire ?

- **Base de connaissances statique :**

- ▶ Connaissances limitées à la période d'entraînement.
- ▶ Incapacité à intégrer des informations récentes ou dynamiques.

- **Hallucinations :**

- ▶ Le modèle invente des réponses crédibles mais factuellement incorrectes.
- ▶ Risque inacceptable dans des domaines critiques comme la médecine.

- **Fine-Tuning :**

- ▶ *Méthode* : Modifier les poids du modèle en l'entraînant sur de nouvelles données.
- ▶ *Inconvénients* : Coût élevé, connaissances statiques, manque de transparence.

- **RAG (Retrieval-Augmented Generation) :**

- ▶ *Méthode* : On recherche des informations externes avant de générer une réponse.
- ▶ *Avantages* : Flexibilité, mise à jour dynamique, transparence (traçabilité).

Fonctionnement du pipeline RAG

Une approche en trois étapes

① Indexation :

- ▶ Découpage des documents en *chunks*.
- ▶ Création de *vectors embeddings* et stockage dans une base de données vectorielle.

② Recherche (Retrieval) :

- ▶ La requête utilisateur est transformée en *embedding*.
- ▶ Recherche des *chunks* les plus similaires dans la base de données.

③ Génération :

- ▶ Les fragments pertinents sont intégrés au *prompt* du LLM.
- ▶ Le LLM génère une réponse basée sur ces informations externes.

Fonctionnement du pipeline RAG




Figure: Architecture du pipeline RAG, illustrant les étapes d'indexation, récupération et génération, ainsi que l'interaction entre les documents, la base de données vectorielle et le LLM

● 1. Le défi de la multimodalité

- ▶ Les documents médicaux sont complexes et contiennent des images, tableaux et graphiques.
- ▶ Un RAG textuel ne peut pas répondre à des questions sur ces éléments.
- ▶ Le pipeline RAG doit donc comprendre la structure visuelle des documents.

● 2. Le défi de l'enrichissement sémantique

- ▶ Les termes médicaux ont de nombreux synonymes et relations complexes.
- ▶ Une simple similarité textuelle est insuffisante pour une recherche pertinente.
- ▶ Le pipeline RAG pourrait intégrer des connaissances structurées pour guider la recherche.

1. Le défi de la multimodalité

- Un retriever est le sous-modèle qui fait la partie du chunking et de l'embedding. La plupart des retrievers peuvent seulement travailler avec du texte.
- Les documents médicaux sont **multimodaux** (texte, images, tableaux, figures).
- Les retrievers classiques (texte seul) ignorent des informations cruciales.
- **Solution** : Utiliser des retrievers multimodaux comme *ColPali*.
 - ▶ Génère des *embeddings* basés sur le texte ET les éléments visuels.
 - ▶ Améliore la qualité de la recherche et la précision des réponses.

2. Le défi de l'enrichissement sémantique

- Les graphes de connaissance (KG) :
 - ▶ Représentent des entités (nœuds) et leurs relations (arêtes).
 - ▶ Apportent un **contexte structuré** qui va au-delà de la simple similarité sémantique.
- **Comment un KG peut améliorer le RAG ?**
 - ▶ **Recherche plus contextuelle** : Enrichit la requête avec des relations sémantiques (synonymes, causes, traitements...).
 - ▶ **Traçabilité** : Permet de retracer la source de l'information, essentielle en médecine.

- **Analyse théorique approfondie** : Étude de l'état de l'art sur les modèles RAG, en particulier pour le domaine médical et l'intégration des Knowledge Graphs.
- **Conception et développement** : Création d'un pipeline RAG hybride depuis la base, utilisant le retriever multimodal *ColPali*.
- **Intégration d'un Knowledge Graph** : Utilisation de l'ontologie médicale *MONDO* pour enrichir les requêtes et améliorer la pertinence.
- **Évaluation rigoureuse** : Validation des performances du modèle avec le benchmark médical *MIRAGE*.

Fonctionnement de mon modèle RAG (partie en commun)

Les étapes clés

- 1 **Élection du corpus** : On peut choisir parmi trois corpus différents qui sont en pdf.
- 2 **Récupération avec ColPali** : On utilise comme retriever ColPali.
- 3 **Enrichissement avec MONDO** : On sélectionne les noms médicaux de la requête avec le LLM. Après, un contexte structuré est extrait du Knowledge Graph MONDO avec le langage Spark.

Exemple contexte extrait du KG

Searching nouns in KG:['phenylketonuria']

Context for question: phenylketonuria (Label: phenylketonuria, Definition: Phenylketonuria (PKU) is the most common inborn error of amino acid metabolism and is characterized by mild to severe mental disability in untreated patients.).

It is also known as PAH deficiency, HPA, non-PKU mild, hyperphenylalaninemia, non-PKU mild, imbecilitus phenylpyruvica, phenylpyruvic oligophrenia.

Relevant medical codes include MESH:D010661, ICD9:270.1

Relationship: phenylketonuria subClassOf disorder of phenylalanine metabolism

Relationship: phenylketonuria subClassOf autosomal recessive disease

Fonctionnement de mon modèle RAG (version 1)

Les étapes clés

- ❶ **Préparation du prompt** : Le modèle combine les k pages cherchées et contexte du KG via un *template*.
- ❷ **Génération** : Le LLM utilise ces informations pour formuler une réponse précise.
- ❸ **Sortie** : La réponse finale est présentée à l'utilisateur.

Fonctionnement de mon modèle RAG (version 2)

Les étapes clés

- 1 **Préparation du prompt** : On cherche les k pages avec la plus grande similarité avec la requête et d'autres k pages avec la plus grande similarité avec le KG contexte. On les lui donne les images et la requête au LLM via un *template*.
- 2 **Génération** : Le LLM utilise ces informations pour formuler une réponse précise.
- 3 **Sortie** : La réponse finale est présentée à l'utilisateur.

- ① **LLM utilisé et ses avantages:** Modèle Gemini 2.5-Flash-Lite.
- ② **Les 'scores' de similarité**
- ③ **La possibilité d'utiliser des seuils pour la recherche**
- ④ **Les seuils et le KG context.**

- **Objectif** : Mesurer l'impact de notre approche hybride (multimodalité + KG) sur les performances.
- **Benchmark utilisé** : *MIRAGE*, un outil d'évaluation spécifiquement conçu pour les questions médicales.
- **Configurations testées** :
 - ▶ Le LLM seul.
 - ▶ RAG simple.
 - ▶ RAG augmenté par le Knowledge Graph (version 1).
 - ▶ RAG augmenté par le Knowledge Graph (version 2).

Benchmark MIRAGE (Medical Information Retrieval-Augmented Generation Evaluation),

Pourquoi utiliser ce benchmark ?

- **Objectif** : Mesurer la fiabilité des systèmes RAG en médecine.
- **Avantages** :
 - ▶ Couvre 5 datasets médicaux avec plus de 7 600 questions.
 - ▶ Scénarios réalistes : *Zero-Shot*, questions à choix multiples, etc.
- Pour des raisons de contraintes temporelles, nous avons sélectionné 200 questions aléatoirement de chacun des cinq datasets de MIRAGE, soit un total de 1 000 questions.

Analyse des résultats

Comparaison des performances globales




Figure: Comparaison des précisions moyennes globales (*Average mean acc*) des configurations avec Gemini 2.5 Flash Lite sur MIRAGE, triées par résultat.

- **Résumé :**

- ▶ L'approche RAG améliore les performances du LLM.
- ▶ Le **Corpus C** s'avère le plus pertinent pour les questions cliniques.
- ▶ L'intégration du **Knowledge Graph MONDO** apporte la meilleure amélioration globale.

- **Limites et défis :**

- ▶ Faibles performances sur le dataset *PubMedQA**, suggérant la nécessité de corpus plus spécialisés.
- ▶ L'effet *lost-in-the-middle* : augmenter le nombre de documents (k) récupérés peut dégrader la performance.

Configuration	MMLU	MedQA	MedMCQA	PubMedQA	BioASQ	Average
RAG Corpus A	0.8600	0.7150	0.6300	0.4550	0.8650	0.7050
RAG + KG	0.8500	0.7700	0.6150	0.4400	0.8500	0.7050
LLM Seule	0.8700	0.7300	0.6350	0.5000	0.8400	0.7150
KG Context	0.8600	0.7300	0.6450	0.4900	0.8500	0.7150
RAG Corpus B	0.8650	0.7200	0.6500	0.4900	0.8600	0.7170
RAG Corpus C	0.8600	0.7750	0.6150	0.5000	0.8850	0.7270
RAG + KG Retrieve	0.8600	0.7800	0.6800	0.4800	0.8700	0.7300

Figure: Précisions moyennes (mean acc) des différentes configurations utilisant Gemini 2.5 Flash Lite sur les datasets MIRAGE et globalement.

KgColPali: EFFICIENT DOCUMENT RETRIEVAL WITH VISION LANGUAGE MODELS AND KNOWLEDGE GRAPHS

Marcos LAHOZ

CentraleSupélec
Université Paris-Saclay

Stage M1 Mathématiques et IA
Année universitaire 2024-2025




CentraleSupélec



L'architecture de ColPali

Un retriever pour documents complexes



ColPali's Architecture

Figure: Architecture de ColPali.

```

general_kg_context_system = '''You are a helpful medical expert tasked with answering a multi-choice
medical question. Follow these steps:
1. Analyze the question and options step-by-step.
2. Analyze any relevant images provided or other context provided.
3. Provide a clear explanation in the "step_by_step_thinking" field.
4. Ensure all special characters (e.g., newlines, LaTeX, tabs)
in the explanation are escaped to be JSON-compliant (e.g., "\\n" for newline, "\\" for backslash).
5. Select a definite answer from the provided options (A, B, C, etc.).
6. Output a JSON dictionary with keys "step_by_step_thinking" (string) and "answer_choice"
(string: A, B, C, etc.), without markdown code fences unless explicitly requested.

```

Format of output:

```

{ "answer_choice": "A",
  "step_by_step_thinking": "Step 1: Analyze...\nStep 2: Conclude..."}

```

Your responses are for research purposes,
so always provide a definite answer in the specified JSON format.'''

```

general_kg_context = Template('''
{{kg_context}}
Here is the question:
{{question}}
Here are the potential choices:
{{options}}''')

```

Figure: Template modèle RAG (version RAG + KG context)

LLM	Method	MIRAGE Benchmark Dataset					Avg.
		MMLU-Med	MedQA-US	MedMCQA	PubMedQA*	BioASQ-Y/N	
GPT-4 (-32k-0613)	CoT	89.44 $\pm$ 0.93	83.97 $\pm$ 1.03	69.88 $\pm$ 0.71	39.60 $\pm$ 2.19	84.30 $\pm$ 1.46	73.44
	MEDRAG	87.24 $\pm$ 1.01	82.80 $\pm$ 1.06	66.65 $\pm$ 0.73	70.60 $\pm$ 2.04	92.56 $\pm$ 1.06	79.97
GPT-3.5 (-16k-0613)	CoT	72.91 $\pm$ 1.35	65.04 $\pm$ 1.34	55.25 $\pm$ 0.77	36.00 $\pm$ 2.15	74.27 $\pm$ 1.76	60.69
	MEDRAG	75.48 $\pm$ 1.30	66.61 $\pm$ 1.32	58.04 $\pm$ 0.76	67.40 $\pm$ 2.10	90.29 $\pm$ 1.19	71.57
Mixtral (8 $\times$ 7B)	CoT	74.01 $\pm$ 1.33	64.10 $\pm$ 1.34	56.28 $\pm$ 0.77	35.20 $\pm$ 2.14	77.51 $\pm$ 1.68	61.42
	MEDRAG	75.85 $\pm$ 1.30	60.02 $\pm$ 1.37	56.42 $\pm$ 0.77	67.60 $\pm$ 2.09	87.54 $\pm$ 1.33	69.48
Llama2 (70B)	CoT	57.39 $\pm$ 1.50	47.84 $\pm$ 1.40	42.60 $\pm$ 0.76	42.20 $\pm$ 2.21	61.17 $\pm$ 1.96	50.24
	MEDRAG	54.55 $\pm$ 1.51	44.93 $\pm$ 1.39	43.08 $\pm$ 0.77	50.40 $\pm$ 2.24	73.95 $\pm$ 1.77	53.38
MEDITRON (70B)	CoT	64.92 $\pm$ 1.45	51.69 $\pm$ 1.40	46.74 $\pm$ 0.77	53.40 $\pm$ 2.23	68.45 $\pm$ 1.87	57.04
	MEDRAG	65.38 $\pm$ 1.44	49.57 $\pm$ 1.40	52.67 $\pm$ 0.77	56.40 $\pm$ 2.22	76.86 $\pm$ 1.70	60.18
PMC-LLaMA (13B)	CoT	52.16 $\pm$ 1.51	44.38 $\pm$ 1.39	46.55 $\pm$ 0.77	55.80 $\pm$ 2.22	63.11 $\pm$ 1.94	52.40
	MEDRAG	52.53 $\pm$ 1.51	42.58 $\pm$ 1.39	48.29 $\pm$ 0.77	56.00 $\pm$ 2.22	65.21 $\pm$ 1.92	52.92

Table 6: Benchmark results of different backbone LLMs on MIRAGE. All numbers are accuracy in percentages.

Figure: Comparaison des précisions du modèle MedRAG sur chaque datasets avec différents LLMs.

Corpus	Retriever	MIRAGE Benchmark Dataset					Average
		MMLU-Med	MedQA-US	MedMCQA	PubMedQA*	BioASQ-Y/N	
None	None	72.91 $\pm$ 1.35	65.04 $\pm$ 1.34	55.25 $\pm$ 0.77	36.00 $\pm$ 2.15	74.27 $\pm$ 1.76	60.69
PubMed (23.9M)	BM25	72.27 $\pm$ 1.36	63.71 $\pm$ 1.35	55.49 $\pm$ 0.77	66.20 $\pm$ 2.12	88.51 $\pm$ 1.28	69.23
	Contriever	71.72 $\pm$ 1.36	63.94 $\pm$ 1.35	54.29 $\pm$ 0.77	65.60 $\pm$ 2.12	85.44 $\pm$ 1.42	68.20
	SPECTER	73.19 $\pm$ 1.34	65.20 $\pm$ 1.34	53.12 $\pm$ 0.77	54.80 $\pm$ 2.23	75.73 $\pm$ 1.72	64.41
	MedCPT	73.09 $\pm$ 1.34	66.69 $\pm$ 1.32	54.94 $\pm$ 0.77	66.40 $\pm$ 2.11	85.76 $\pm$ 1.41	69.38
	RRF-2	75.57 $\pm$ 1.30	64.34 $\pm$ 1.34	55.34 $\pm$ 0.77	69.00 $\pm$ 2.01	87.06 $\pm$ 1.35	70.26
	RRF-4	73.37 $\pm$ 1.34	64.73 $\pm$ 1.34	54.75 $\pm$ 0.77	67.20 $\pm$ 2.10	88.51 $\pm$ 1.28	69.71
StatPearls (301.2k)	BM25	71.63 $\pm$ 1.37	65.67 $\pm$ 1.33	54.89 $\pm$ 0.77	27.60 $\pm$ 2.00	60.36 $\pm$ 1.97	56.03
	Contriever	73.28 $\pm$ 1.34	67.48 $\pm$ 1.31	54.24 $\pm$ 0.77	28.80 $\pm$ 2.03	58.41 $\pm$ 1.98	56.44
	SPECTER	73.74 $\pm$ 1.33	64.73 $\pm$ 1.34	52.83 $\pm$ 0.77	23.20 $\pm$ 1.89	57.77 $\pm$ 1.99	54.45
	MedCPT	72.82 $\pm$ 1.35	64.89 $\pm$ 1.34	54.17 $\pm$ 0.77	27.60 $\pm$ 2.00	60.68 $\pm$ 1.96	56.03
	RRF-2	72.64 $\pm$ 1.35	65.67 $\pm$ 1.33	54.63 $\pm$ 0.77	30.00 $\pm$ 2.05	61.17 $\pm$ 1.96	56.82
	RRF-4	73.83 $\pm$ 1.33	65.12 $\pm$ 1.34	53.81 $\pm$ 0.77	30.60 $\pm$ 2.06	59.71 $\pm$ 1.97	56.61
Textbooks (125.8k)	BM25	74.66 $\pm$ 1.32	66.54 $\pm$ 1.32	54.05 $\pm$ 0.77	30.20 $\pm$ 2.05	60.03 $\pm$ 1.97	57.10
	Contriever	74.10 $\pm$ 1.33	67.16 $\pm$ 1.32	54.53 $\pm$ 0.77	26.60 $\pm$ 1.98	60.19 $\pm$ 1.97	56.52
	SPECTER	72.82 $\pm$ 1.35	67.40 $\pm$ 1.31	53.29 $\pm$ 0.77	25.60 $\pm$ 1.95	55.50 $\pm$ 2.00	54.92
	MedCPT	74.93 $\pm$ 1.31	66.22 $\pm$ 1.33	54.41 $\pm$ 0.77	29.20 $\pm$ 2.03	61.33 $\pm$ 1.96	57.22
	RRF-2	76.68 $\pm$ 1.28	65.91 $\pm$ 1.33	54.79 $\pm$ 0.77	31.00 $\pm$ 2.07	59.39 $\pm$ 1.98	57.55
	RRF-4	75.76 $\pm$ 1.30	66.06 $\pm$ 1.33	55.56 $\pm$ 0.77	30.40 $\pm$ 2.06	60.68 $\pm$ 1.96	57.69
Wikipedia (29.9M)	BM25	73.37 $\pm$ 1.34	63.47 $\pm$ 1.35	54.10 $\pm$ 0.77	26.40 $\pm$ 1.97	71.36 $\pm$ 1.82	57.74
	Contriever	74.10 $\pm$ 1.33	65.99 $\pm$ 1.33	54.03 $\pm$ 0.77	26.40 $\pm$ 1.97	69.90 $\pm$ 1.85	58.08
	SPECTER	72.18 $\pm$ 1.36	63.63 $\pm$ 1.35	52.71 $\pm$ 0.77	22.20 $\pm$ 1.86	66.83 $\pm$ 1.89	55.51
	MedCPT	71.99 $\pm$ 1.36	65.12 $\pm$ 1.34	55.15 $\pm$ 0.77	29.00 $\pm$ 2.03	73.46 $\pm$ 1.78	58.95
	RRF-2	74.20 $\pm$ 1.33	64.57 $\pm$ 1.34	54.72 $\pm$ 0.77	31.00 $\pm$ 2.07	76.21 $\pm$ 1.71	60.14
	RRF-4	73.19 $\pm$ 1.34	64.96 $\pm$ 1.34	54.53 $\pm$ 0.77	31.00 $\pm$ 2.07	72.01 $\pm$ 1.81	59.14
MedCorp (65.3M)	BM25	73.65 $\pm$ 1.34	65.91 $\pm$ 1.33	56.78 $\pm$ 0.77	66.20 $\pm$ 2.12	87.70 $\pm$ 1.32	70.05
	Contriever	75.48 $\pm$ 1.30	64.10 $\pm$ 1.34	56.11 $\pm$ 0.77	62.40 $\pm$ 2.17	84.95 $\pm$ 1.44	68.61
	SPECTER	74.38 $\pm$ 1.32	65.44 $\pm$ 1.33	54.41 $\pm$ 0.77	55.80 $\pm$ 2.22	73.14 $\pm$ 1.78	64.63
	MedCPT	74.75 $\pm$ 1.32	67.40 $\pm$ 1.31	55.85 $\pm$ 0.77	66.40 $\pm$ 2.11	85.92 $\pm$ 1.40	70.06
	RRF-2	73.74 $\pm$ 1.33	67.24 $\pm$ 1.32	56.08 $\pm$ 0.77	67.80 $\pm$ 2.09	88.19 $\pm$ 1.30	70.61
	RRF-4	75.48 $\pm$ 1.30	66.61 $\pm$ 1.32	58.04 $\pm$ 0.78	67.40 $\pm$ 2.10	90.29 $\pm$ 1.39	71.57